Modelos (S)ARIMA

Forma General, Interpretaciones y Aplicaciones

ACF, PACF, Criterios de Información y Ejemplos en Python con Datos Financieros

Elaborado por

Sofia Palma

Finanzas Cuantitativas

Universidad Panamericana

Abril 2026

Índice

1 Forma General del Modelo (S)ARIMA **2**
- 1.1 Notación Completa . . . 2
- 1.2 Definición de Cada Operador . . . 2
- 1.3 Expansión Explícita para SARIMA(1,1,1)(1,1,1)$_{12}$ . . . 2

2 Condiciones de Estacionariedad e Invertibilidad **4**

3 Herramientas de Identificación: ACF y PACF **4**
- 3.1 Función de Autocorrelación (ACF) . . . 4
- 3.2 Función de Autocorrelación Parcial (PACF) . . . 5
- 3.3 Patrones de Identificación . . . 5

4 Criterios de Selección de Modelos **6**
- 4.1 AIC, BIC, SSE y Log-Verosimilitud . . . 6
- 4.2 Test de Ljung-Box . . . 7

5 Principio de Parsimonia **8**

6 Metodología Completa Box-Jenkins para SARIMA **9**

7 Ejemplos en Python con Base de Datos Financiera **10**
- 7.1 Descripción de la Base de Datos . . . 10
- 7.2 Ejemplo 1: Identificación y Diagnóstico ACF/PACF . . . 10
- 7.3 Ejemplo 2: Estimación y Selección de Modelos ARIMA . . . 11
- 7.4 Ejemplo 3: SARIMA Estacional y Pronóstico . . . 13

8 Tabla Resumen: Guía Rápida de Uso **15**

9 Interpretaciones Económicas Clave **16**

10 Conclusiones **16**

1. Forma General del Modelo (S)ARIMA

1.1. Notación Completa

El modelo **SARIMA**$(p, d, q)(P, D, Q)_s$ —Seasonal AutoRegressive Integrated Moving Average— es la extensión estacional del modelo ARIMA clásico. Su forma general en notación de operadores de rezago es:

Ecuación General del Modelo SARIMA

$$\underbrace{\Phi_P(B^s)}_{\text{AR estacional}} \underbrace{\phi_p(B)}_{\text{AR regular}} \underbrace{\Delta^d \Delta_s^D}_{\text{Diferenciaciones}} Y_t = \underbrace{\Theta_Q(B^s)}_{\text{MA estacional}} \underbrace{\theta_q(B)}_{\text{MA regular}} \varepsilon_t \tag{1}$$

donde $\varepsilon_t \sim \text{RB}(0, \sigma_\varepsilon^2)$ es ruido blanco.

1.2. Definición de Cada Operador

Los polinomios de rezago se definen como sigue. El operador de rezago B actúa sobre la serie como $BY_t = Y_{t-1}$, y $B^s Y_t = Y_{t-s}$:

$$\phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p \tag{2}$$

$$\theta_q(B) = 1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q \tag{3}$$

$$\Phi_P(B^s) = 1 - \Phi_1 B^s - \Phi_2 B^{2s} - \cdots - \Phi_P B^{Ps} \tag{4}$$

$$\Theta_Q(B^s) = 1 + \Theta_1 B^s + \Theta_2 B^{2s} + \cdots + \Theta_Q B^{Qs} \tag{5}$$

$$\Delta^d = (1 - B)^d \tag{6}$$

$$\Delta_s^D = (1 - B^s)^D \tag{7}$$

1.3. Expansión Explícita para SARIMA(1,1,1)(1,1,1)$_{12}$

Para el modelo más común en finanzas con datos mensuales —periodicidad $s = 12$—, la ecuación (1) se expande como:

$$\left(1 - \Phi_1 B^{12}\right)\left(1 - \phi_1 B\right)\left(1 - B\right)\left(1 - B^{12}\right) Y_t = \left(1 + \Theta_1 B^{12}\right)\left(1 + \theta_1 B\right) \varepsilon_t \tag{8}$$

Expandiendo el lado izquierdo se obtiene:

$$\begin{aligned} Y_t = {} & (1 + \phi_1) Y_{t-1} - \phi_1 Y_{t-2} + Y_{t-12}(1 + \Phi_1) - (1 + \phi_1)(1 + \Phi_1) Y_{t-13} \\ & + \phi_1 (1 + \Phi_1) Y_{t-14} - \Phi_1 Y_{t-24} + \cdots + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-12} + \theta_1 \Theta_1 \varepsilon_{t-13} \end{aligned} \tag{9}$$

La Tabla 1 resume todos los parámetros del modelo con sus interpretaciones económicas.

Cuadro 1: Parámetros del modelo SARIMA$(p, d, q)(P, D, Q)_s$ y su interpretación

Par.	Nombre	Interpretación económica	Rango	Tipo
p	Orden AR no estacional	Cuántos periodos pasados de Y influyen en Y_t hoy	$[0, 3]$	Entero
d	Diferenciación regular	Número de veces que se diferencia para lograr estacionariedad	$\{0, 1, 2\}$	Entero
q	Orden MA no estacional	Cuántos errores pasados (ε) se incluyen en el modelo	$[0, 3]$	Entero
P	Orden AR estacional	Autoregresión cada s periodos (patrón anual, trimestral...)	$\{0, 1\}$	Entero
D	Diferenciación estacional	Elimina estacionalidad (e.g., restar el mismo mes del año anterior)	$\{0, 1\}$	Entero
Q	Orden MA estacional	Errores estacionales rezagados que afectan Y_t	$\{0, 1\}$	Entero
s	Período estacional	Longitud del ciclo: 12 (mensual), 4 (trimestral), 52 (semanal)	$\{4, 12, 52\}$	Fijo
ϕ_i	Coefs. AR	Persistencia de la serie (similar a coef. AR(1))	$\lvert\phi\rvert < 1$	Real
θ_j	Coefs. MA	Peso del j-ésimo choque pasado en Y_t	$\lvert\theta\rvert < 1$	Real
Φ_i, Θ_j	Coefs. estacionales	Mismo papel pero a rezagos múltiplos de s	$\lvert\cdot\rvert < 1$	Real

2. Condiciones de Estacionariedad e Invertibilidad

Condiciones necesarias para SARIMA válido

1. **Estacionariedad**: todas las raíces de $\phi_p(z) = 0$ y $\Phi_P(z^s) = 0$ deben caer *fuera* del círculo unitario $|z| > 1$.
2. **Invertibilidad**: todas las raíces de $\theta_q(z) = 0$ y $\Theta_Q(z^s) = 0$ deben caer fuera del círculo unitario.
3. **Parsimonia**: $p + d + q + P + D + Q \leq C$ con C acotada por el tamaño muestral.

La Figura 1 muestra el círculo unitario en el plano complejo.

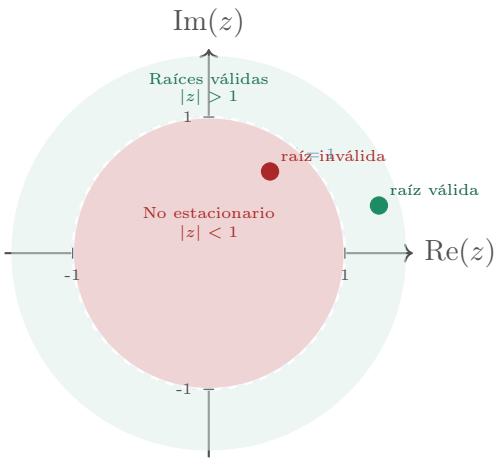

Figura 1: Círculo unitario en el plano complejo. Las raíces de los polinomios AR y MA deben ubicarse fuera del círculo ($|z| > 1$) para garantizar estacionariedad e invertibilidad respectivamente.

3. Herramientas de Identificación: ACF y PACF

3.1. Función de Autocorrelación (ACF)

Definición: ACF

La función de autocorrelación en el rezago k se define como:

$$\rho_k = \frac{\mathrm{Cov}(Y_t, Y_{t-k})}{\mathrm{Var}(Y_t)} = \frac{\gamma_k}{\gamma_0}, \qquad k = 0, 1, 2, \ldots \tag{10}$$

donde $\gamma_k = E[(Y_t - \mu)(Y_{t-k} - \mu)]$ es la autocovarianza de orden k.

3.2. Función de Autocorrelación Parcial (PACF)

Definición: PACF (Esperanza Condicional)

La PACF mide la correlación entre Y_t e Y_{t-k} eliminando la influencia de los rezagos intermedios $Y_{t-1}, \ldots, Y_{t-k+1}$:

$$\alpha_k = \mathrm{Corr}(Y_t, Y_{t-k} \mid Y_{t-1}, \ldots, Y_{t-k+1}) \tag{11}$$

Es equivalente al último coeficiente en una regresión AR(k): $Y_t = \phi_{k,1} Y_{t-1} + \cdots + \phi_{k,k} Y_{t-k} + \varepsilon_t$, es decir, $\alpha_k = \hat{\phi}_{k,k}$.

3.3. Patrones de Identificación

La Tabla 2 resume cómo usar ACF y PACF para identificar el tipo de proceso.

Cuadro 2: Patrones de ACF y PACF para identificación de modelos ARIMA

Proceso	**ACF**	**PACF**	**Implicación**
AR(p)	Decae exponencialmente o con oscilaciones	**Corte abrupto** en el rezago p	Usar PACF para determinar p
MA(q)	**Corte abrupto** en el rezago q	Decae exponencialmente	Usar ACF para determinar q
ARMA(p, q)	Decae exponencialmente (después de q)	Decae exponencialmente (después de p)	Ambas decaen: usar AIC/BIC
No estacionaria	Decae muy lentamente (casi lineal)	Primer rezago ≈ 1, luego corte	Diferenciar ($d \geq 1$)
SAR(P)$_s$	Picos en $s, 2s, 3s, \ldots$ decayendo	**Corte** en el rezago Ps	Componente estacional AR
SMA(Q)$_s$	**Corte** en el rezago Qs	Picos en $s, 2s, 3s, \ldots$ decayendo	Componente estacional MA
Ruido blanco	Todas $\rho_k \approx 0$	Todas $\alpha_k \approx 0$	No hay estructura que modelar

Limitación importante del ACF aplicado a AR puro

Cuando se tiene un proceso AR puro y se analiza solo la ACF, esta **no se corta abruptamente** sino que decae de forma geométrica o sinusoidal hasta el infinito. Por esta razón, la ACF por sí sola **no permite determinar** el orden p de un AR. Se debe recurrir a la PACF, que sí se corta después del rezago p.

La Figura 2 ilustra visualmente los patrones teóricos.

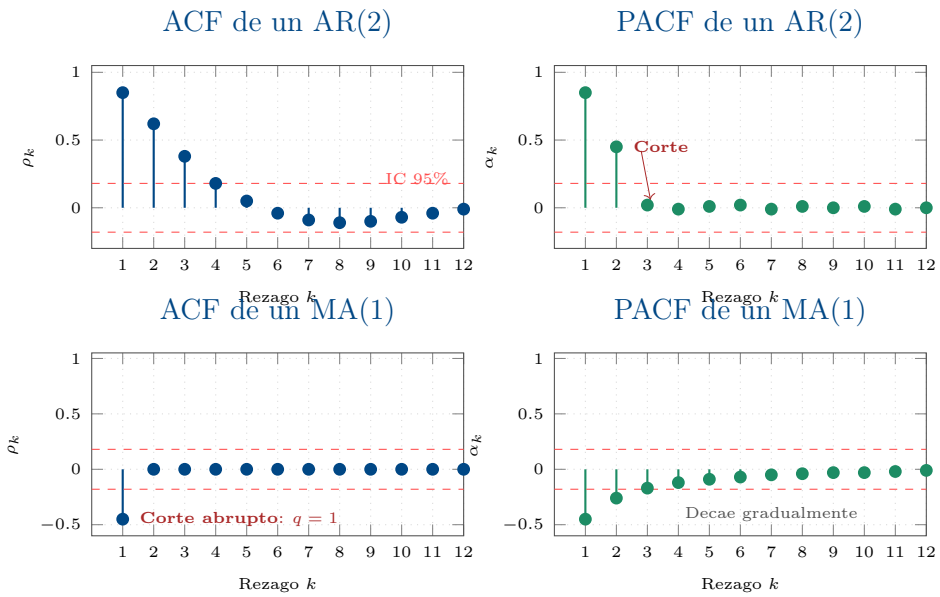

Figura 2: Patrones teóricos de ACF y PACF. *Arriba*: AR(2) — la PACF se corta en el rezago 2 mientras la ACF decae. *Abajo*: MA(1) — la ACF se corta en el rezago 1 mientras la PACF decae gradualmente.

4. Criterios de Selección de Modelos

4.1. AIC, BIC, SSE y Log-Verosimilitud

Criterio de Información de Akaike (AIC)

$$\text{AIC} = -2\,\ell(\hat{\theta}) + 2k \tag{12}$$

Penaliza cada parámetro extra con un costo fijo de 2. Preferido para **pronóstico**: admite modelos ligeramente más complejos.

Criterio de Información Bayesiano (BIC)

$$\text{BIC} = -2\,\ell(\hat{\theta}) + k\ln(n) \tag{13}$$

Penaliza más fuertemente a medida que crece n. Para $n > 7.4$, BIC $>$ AIC. Preferido para **inferencia**: selecciona modelos más aust eros.

Suma de Errores Cuadrados (SSE) y Log-Verosimilitud

$$\text{SSE} = \sum_{t=1}^{n} \hat{\varepsilon}_t^2 \tag{14}$$

$$\ell(\hat{\theta}) = -\frac{n}{2}\ln(2\pi\hat{\sigma}^2) - \frac{1}{2\hat{\sigma}^2}\sum_{t=1}^{n}\hat{\varepsilon}_t^2 \tag{15}$$

La log-verosimilitud mide ajuste puro. **Siempre aumenta** al agregar parámetros: no se usa sola para comparar modelos.

La Tabla 3 sintetiza las diferencias entre criterios.

Cuadro 3: Comparación detallada de criterios de selección para modelos SARIMA

Criterio	Fórmula	Penalización	Uso recomendado	Mejor valor
AIC	$-2\ell + 2k$	Moderada: $2k$	Pronóstico fuera de muestra	Mínimo
AICc	$-2\ell + \frac{2kn}{n-k-1}$	AIC corregido muestras pequeñas	Cuando $n/k < 40$	Mínimo
BIC	$-2\ell + k\ln n$	Fuerte: $k\ln n$	Inferencia, parsimonia	Mínimo
Log-Ver.	$\ell(\hat{\theta})$	Ninguna	Diagnóstico, pruebas LR	Máximo
SSE	$\sum \hat{\varepsilon}_t^2$	Ninguna	Comparar ajuste en muestra	Mínimo
RMSE	$\sqrt{\text{MSE}}$	Ninguna	Evaluación de pronóstico	Mínimo

4.2. Test de Ljung-Box

Estadístico de Ljung-Box

Una vez seleccionado el modelo, se verifica que los residuos $\hat{\varepsilon}_t$ sean ruido blanco:

$$Q_{LB}(m) = n(n+2)\sum_{k=1}^{m}\frac{\hat{\rho}_k^2}{n-k} \sim \chi^2_{m-p-q-P-Q} \tag{16}$$

H_0: los residuos son ruido blanco (no hay autocorrelación restante).
Rechazar H_0 indica que el modelo no capturó toda la estructura de la serie y debe reidentificarse.

5. Principio de Parsimonia

Restricción de Parsimonia

$$p + d + q + P + D + Q \;\leq\; C \tag{17}$$

La constante C depende del tamaño muestral: regla práctica $C \approx n/10$, con $C \in [6, 12]$ en la mayoría de aplicaciones financieras.

La Figura 3 ilustra el balance sesgo-varianza al aumentar la complejidad del modelo.

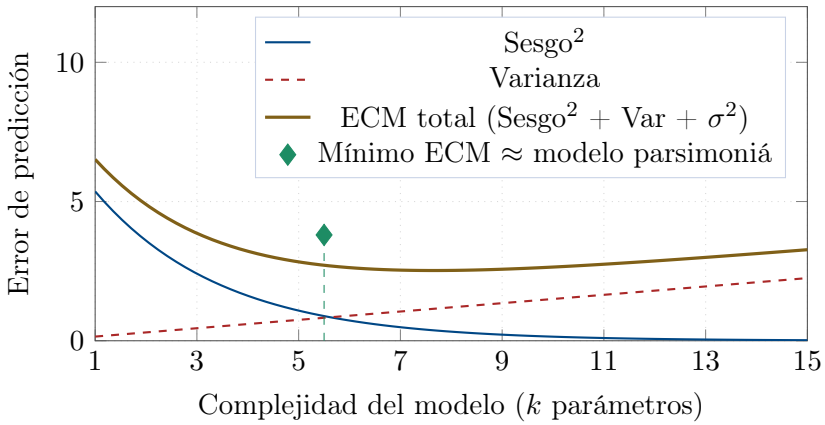

Figura 3: Balance sesgo-varianza. El modelo óptimo no es el más complejo (mínimo sesgo) ni el más simple (mínima varianza), sino el que minimiza el ECM total, principio que guia la parsimonia.

6. Metodología Completa Box-Jenkins para SARIMA

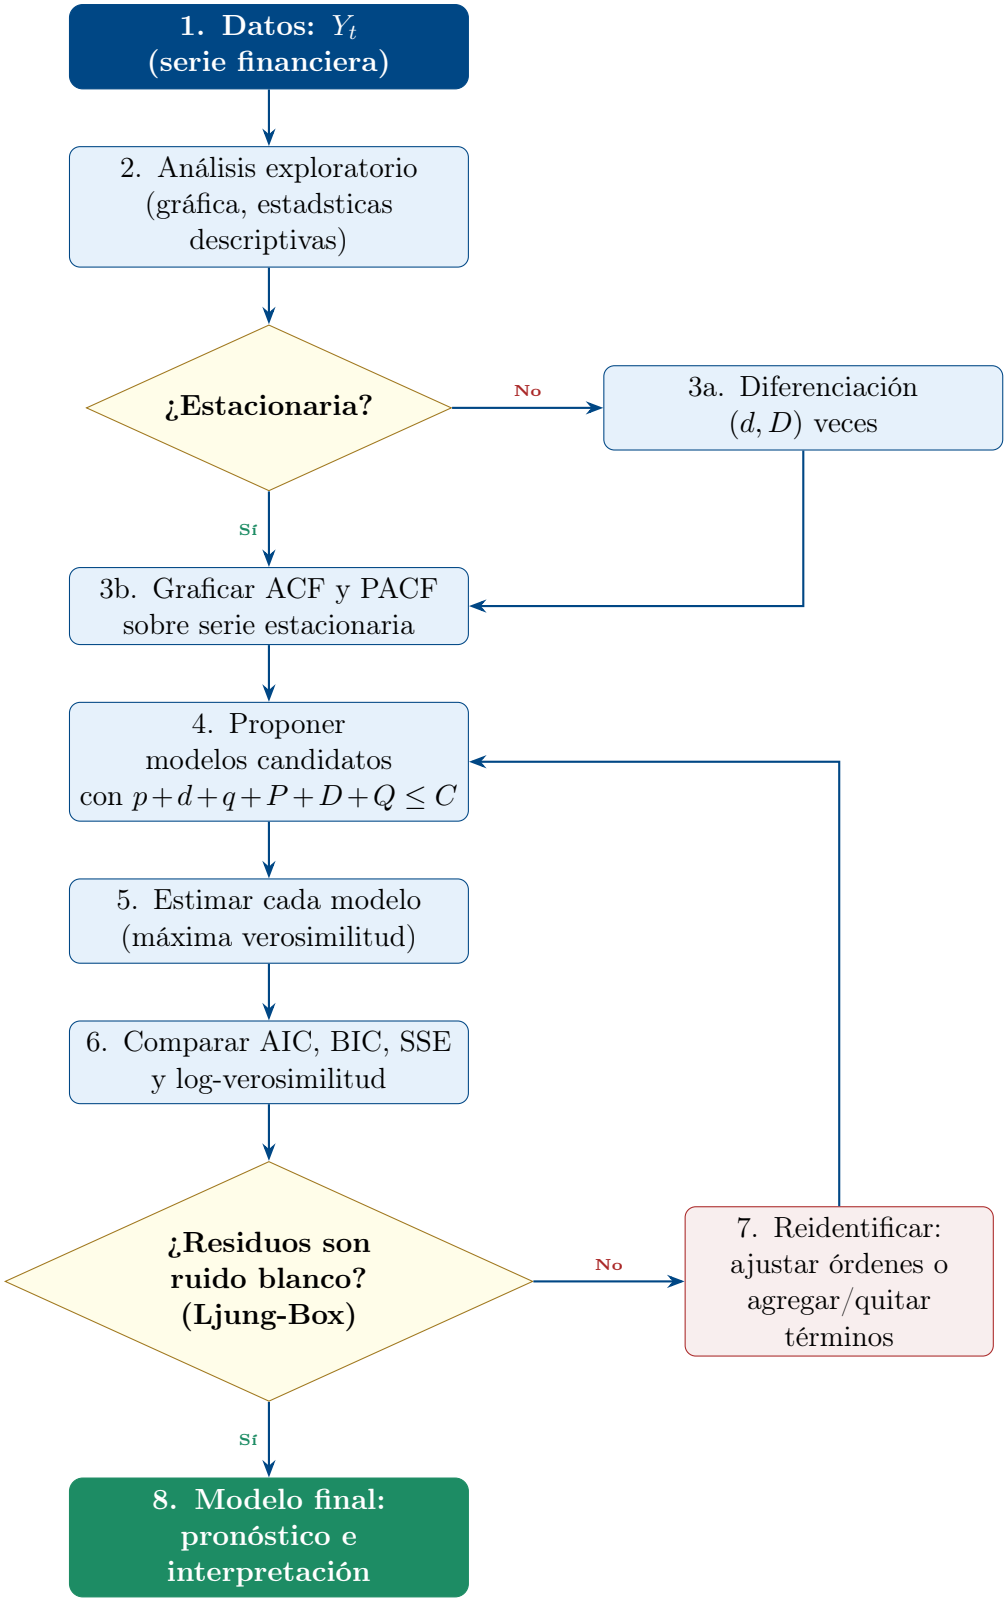

Figura 4: Metodología Box-Jenkins completa para la especificación de modelos SARIMA. El proceso es iterativo: si los residuos no pasan el test de Ljung-Box, se regresa a la etapa de identificación.

7. Ejemplos en Python con Base de Datos Financiera

7.1. Descripción de la Base de Datos

Se utiliza una base de datos de **rendimientos diarios del IPC (Índice de Precios y Cotizaciones)** de la Bolsa Mexicana de Valores, con 299 observaciones de enero 2019 a febrero 2020. La variable principal es el rendimiento porcentual: $r_t = \frac{P_t - P_{t-1}}{P_{t-1}} \times 100$.

Cuadro 4: Estadísticas descriptivas de la base de datos financiera (IPC diario)

Estadística	Valor	Estadística	Valor
Observaciones (n)	299	Mínimo rendimiento	−3.97%
Periodo	2019–2020	Máximo rendimiento	+4.82%
Precio inicial	41,000	Media rendimiento	+0.037%
Precio final	46,150	Desviación estánd.	1.207%
Variable expl. usada	r_t	Frecuencia	Diaria (hábil)

7.2. Ejemplo 1: Identificación y Diagnóstico ACF/PACF

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.stattools import adfuller, acf, pacf
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

#         1. Cargar datos


df = pd.read_csv("ipc_data.csv", parse_dates=["Date"], index_col=
    "Date")
r  = df["Return"].dropna()          # rendimientos porcentuales
    diarios
print(f"Observaciones: {len(r)}")
print(r.describe().round(4))

#         2. Prueba de Dickey-Fuller Aumentada (ADF)


resultado_adf = adfuller(r, autolag="AIC")
print(f"\nEstad\'istico ADF : {resultado_adf[0]:.4f}")
print(f"p-valor           : {resultado_adf[1]:.6f}")
print(f"Valores cr\'iticos: {resultado_adf[4]}")
# p < 0.05 -> la serie es ESTACIONARIA (d=0 para rendimientos)

#         3. Graficar ACF y PACF


fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf( r, lags=30, ax=axes[0], title="ACF - Rendimientos IPC",
```

```
            alpha=0.05, color="#1D4E89")
plot_pacf(r, lags=30, ax=axes[1], title="PACF - Rendimientos IPC"
    ,
            alpha=0.05, color="#27AE60", method="ywm")
plt.tight_layout()
plt.savefig("acf_pacf_ipc.png", dpi=150, bbox_inches="tight")
plt.show()

#         4. Identificaci\'on manual a partir de ACF/PACF

acf_vals  = acf(r,  nlags=15, fft=True)
pacf_vals = pacf(r, nlags=15, method="ywm")
ic95 = 1.96 / np.sqrt(len(r))

print(f"\nIC 95% = +/- {ic95:.4f}")
print("\nRezagos significativos en ACF :")
for k, v in enumerate(acf_vals[1:], 1):
    if abs(v) > ic95:
        print(f"  Rezago {k}: rho = {v:.4f}  <- SIGNIFICATIVO")
print("\nRezagos significativos en PACF:")
for k, v in enumerate(pacf_vals[1:], 1):
    if abs(v) > ic95:
        print(f"  Rezago {k}: alpha = {v:.4f}  <- SIGNIFICATIVO")
```

Listing 1: Carga de datos, prueba ADF, graficación ACF/PACF y diagnóstico de estacionariedad

Interpretación del Ejemplo 1

- Si el p-valor ADF < 0.05, la serie es estacionaria y **no se necesita diferenciar** ($d = 0$). Los rendimientos financieros generalmente son estacionarios.
- El intervalo de confianza al 95% para la ACF/PACF es $\pm 1.96/\sqrt{n}$. Solo los rezagos cuya barra supere este umbral son estadísticamente significativos.
- Si la ACF decae lentamente (tipo escalera), la **serie de precios** (no rendimientos) requiere $d = 1$.

7.3. Ejemplo 2: Estimación y Selección de Modelos ARIMA

```
import itertools
import warnings
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.stats.diagnostic import acorr_ljungbox

warnings.filterwarnings("ignore")

#         1. Busqueda en grilla de modelos


p_range = range(0, 4)    # p in {0,1,2,3}
q_range = range(0, 4)    # q in {0,1,2,3}
d       = 0              # rendimientos ya son estacionarios

resultados = []
for p, q in itertools.product(p_range, q_range):
```

```python
    if p + q == 0:           # evitar modelo nulo
        continue
    if p + d + q > 6:        # restriccion de parsimonia C=6
        continue
    try:
        modelo = ARIMA(r, order=(p, d, q)).fit(method="innovations_mle")
        lb_test = acorr_ljungbox(modelo.resid, lags=[10], return_df=True)
        resultados.append({
            "Modelo"  : f"ARIMA({p},{d},{q})",
            "p"       : p, "d": d, "q": q,
            "Params"  : p + q,
            "AIC"     : round(modelo.aic,  2),
            "BIC"     : round(modelo.bic,  2),
            "LogLik"  : round(modelo.llf,  2),
            "LjungBox": round(lb_test["lb_pvalue"].values[0], 4),
        })
    except Exception:
        pass

df_res = pd.DataFrame(resultados).sort_values("AIC")
print(df_res.to_string(index=False))

#         2. Mejor modelo


mejor = df_res.iloc[0]
print(f"\nModelo seleccionado: {mejor['Modelo']}")
print(f"  AIC = {mejor['AIC']}  |  BIC = {mejor['BIC']}")
print(f"  Ljung-Box p = {mejor['LjungBox']} -> ",
      "Residuos OK" if mejor["LjungBox"] > 0.05 else "Revisar modelo")

#         3. Ajuste del modelo ganador


p_opt, q_opt = int(mejor["p"]), int(mejor["q"])
modelo_final = ARIMA(r, order=(p_opt, d, q_opt)).fit()
print(modelo_final.summary())

#         4. Graficos de diagnostico


fig = modelo_final.plot_diagnostics(figsize=(12, 8))
plt.suptitle(f"Diagn\'ostico de residuos: {mejor['Modelo']}", y=1.01,
             fontsize=13, color="#003366")
plt.tight_layout()
plt.savefig("diagnostico_arima.png", dpi=150, bbox_inches="tight")
plt.show()
```

Listing 2: Estimación de múltiples modelos ARIMA, comparación por AIC/BIC y diagnóstico de residuos

Interpretación del Ejemplo 2

- El modelo con **menor AIC** (o BIC) entre todos los candidatos válidos se considera el mejor bajo el criterio de parsimonia.
- Un p-valor de Ljung-Box > 0.05 indica que los residuos son ruido blanco: el modelo capturó toda la estructura lineal de la serie.
- El método `innovations_mle` implementa máxima verosimilitud exacta, equivalente a maximizar $\ell(\hat{\theta})$ en la ecuación (15).
- Si el modelo tiene coeficientes no significativos (t-stat < 1.96), puede imponerse $\phi_i = 0$ o $\theta_j = 0$ para mejorar parsimonia.

7.4. Ejemplo 3: SARIMA Estacional y Pronóstico

```python
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches
import numpy as np
from statsmodels.tsa.statespace.sarimax import SARIMAX

#         1. Modelo SARIMA(1,0,1)(1,0,1)_5 (estacionalidad semanal)
#     s=5: dias habiles por semana
modelo_sarima = SARIMAX(
    r,
    order            = (1, 0, 1),    # p=1, d=0, q=1
    seasonal_order   = (1, 0, 1, 5),# P=1, D=0, Q=1, s=5
    trend            = "c",           # incluye constante
    enforce_stationarity  = True,
    enforce_invertibility = True,
).fit(disp=False)

print(modelo_sarima.summary())
print(f"\nAIC  = {modelo_sarima.aic:.2f}")
print(f"BIC  = {modelo_sarima.bic:.2f}")
print(f"HQIC = {modelo_sarima.hqic:.2f}")

#         2. Pronostico a 10 dias habiles (2 semanas)

pronostico = modelo_sarima.get_forecast(steps=10)
media_pred = pronostico.predicted_mean
ic         = pronostico.conf_int(alpha=0.05)    # IC 95%

#         3. Visualizacion

fig, ax = plt.subplots(figsize=(12, 5))

# Ultimos 60 datos de la muestra
ax.plot(r.index[-60:], r.values[-60:],
        color="#003366", lw=1.2, label="Rendimiento historico")

# Pronostico
steps    = range(1, 11)
ax.plot(steps, media_pred.values,
        color="#E74C3C", lw=2, marker="o", ms=5, label="Pronostico SARIMA")
```

```python
ax.fill_between(steps, ic.iloc[:, 0], ic.iloc[:, 1],
                alpha=0.25, color="#E74C3C", label="IC 95%")

ax.axhline(0, color="gray", lw=0.8, linestyle="--")
ax.set_xlabel("Periodo")
ax.set_ylabel("Rendimiento diario (%)")
ax.set_title("Pronostico SARIMA(1,0,1)(1,0,1)_5 -- Rendimientos IPC",
             fontsize=13, color="#003366")
ax.legend(fontsize=9)
plt.tight_layout()
plt.savefig("pronostico_sarima.png", dpi=150, bbox_inches="tight")
plt.show()

#         4. Prueba de Ljung-Box sobre residuos del SARIMA

from statsmodels.stats.diagnostic import acorr_ljungbox
lb = acorr_ljungbox(modelo_sarima.resid, lags=[5, 10, 20], return_df=True)
print("\nTest Ljung-Box sobre residuos SARIMA:")
print(lb.round(4))
```

Listing 3: Ajuste de SARIMA con estacionalidad semanal ($s = 5$), pronóstico a 10 dias y bandas de confianza

Interpretación del Ejemplo 3

- **Estacionalidad semanal**: en datos financieros diarios el efecto "día de la semana" puede capturarse con $s = 5$. Si se usan datos mensuales de un sector con ciclo anual, usar $s = 12$.
- El pronóstico de SARIMA converge a la media incondicional conforme el horizonte $h \to \infty$. Las bandas de confianza se **ensanchan** con el horizonte por acumulación de incertidumbre.
- Si $\Phi_1 \approx 0$ y $\Theta_1 \approx 0$ en el resumen, el componente estacional no es necesario y se simplifica a ARIMA$(1, 0, 1)$.
- Los p-valores del Ljung-Box a distintos rezagos ($m = 5, 10, 20$) dan una visión más completa que un solo valor de m.

8. Tabla Resumen: Guía Rápida de Uso

Cuadro 5: Guía rápida de identificación de órdenes en SARIMA para datos financieros

Componente	Herramienta	Señal diagnóstica	Acción
Tendencia / d	Gráfica, ADF, KPSS	ACF decae muy lentamente; ADF no rechaza H_0	Diferenciar: $d = 1$ (precios), $d = 0$ (rendimientos)
Estacionalidad / D	Gráfica, HEGY, peaks ACF	Picos en $s, 2s$ de la ACF; patrón visual claro	Diferenciación estacional Δ_s o $D = 1$
Orden AR (p)	PACF (sobre serie estacionaria)	Corte abrupto en rezago p; luego $\alpha_k \approx 0$	Fijar p en el rezago del corte
Orden MA (q)	ACF (sobre serie estacionaria)	Corte abrupto en rezago q; luego $\rho_k \approx 0$	Fijar q en el rezago del corte
Orden SAR (P)	PACF en rezagos $s, 2s, \ldots$	Corte en Ps-ésimo rezago estacional	$P \in \{0, 1\}$; rara vez $P = 2$
Orden SMA (Q)	ACF en rezagos $s, 2s, \ldots$	Corte en Qs-ésimo rezago estacional	$Q \in \{0, 1\}$; rara vez $Q = 2$
Selección final	AIC, BIC, Ljung-Box	Menor AIC/BIC + p-LB > 0.05	Modelo más parsimonioso que pasa diagnósticos

9. Interpretaciones Económicas Clave

Cuadro 6: Interpretación económica de los parámetros estimados de un SARIMA

Parámetro	Nombre	Interpretación económica
$\hat{\phi}_1 > 0$	Persistencia AR positiva	El mercado tiene "momentum": rendimientos altos hoy predicen rendimientos altos mañana (seguimiento de tendencia)
$\hat{\phi}_1 < 0$	Persistencia AR negativa	Reversión a la media: un rendimiento alto hoy predice correción mañana (mercado eficiente de corto plazo)
$\hat{\theta}_1 < 0$	Corrección MA	Un choque negativo ($\varepsilon_{t-1} < 0$) genera rebote parcial en Y_t: ajuste típico de mercados ilíquidos
$\hat{\Phi}_1 > 0$	Estacionalidad AR	El comportamiento del mismo periodo del ciclo pasado (e.g., enero del año anterior) se reproduce en el periodo actual
$d = 1$	Integración de orden 1	La serie de **precios** es una caminata aleatoria: consistente con la Hipótesis de Mercados Eficientes en su forma débil
$d = 0$	Estacionariedad	Los **rendimientos** son estacionarios: su media y varianza no cambian con el tiempo (supuesto clásico de eficiencia)
σ_ε^2 grande	Alta volatilidad residual	Parte significativa del movimiento no es predecible (ruido de mercado). Considerar GARCH para modelar heterocedasticidad

10. Conclusiones

El modelo SARIMA$(p, d, q)(P, D, Q)_s$ provee un marco unificado para modelar series de tiempo con memoria, tendencia y estacionalidad. Su forma general —ecuación (1)— combina cuatro operadores polinomiales que actuan multiplicativamente sobre la serie diferenciada.

Las herramientas de identificación (ACF y PACF), los criterios de selección (AIC, BIC, log-verosimilitud) y el test de diagnóstico (Ljung-Box) conforman una metodología iterativa —Box-Jenkins— que bajo el principio de parsimonia garantiza modelos robustos y generalizables para el pronóstico financiero.

En Python, la librería `statsmodels` implementa todos los pasos descritos a través de las clases `ARIMA` y `SARIMAX`, permitiendo estimar, comparar y pronosticar con pocas líneas de código, tal como ilustran los tres ejemplos de las secciones anteriores.