Procesos (S)ARIMAX

Modelo Estacional con Variable Exógena

Principio de Parsimonia, Identificación y Criterios de Selección

Elaborado por

Sofía Palma

Finanzas Cuantitativas

Universidad Panamericana

Guadalajara, Jalisco • Abril 2026

?contentsname?

1 Introducción a los Procesos ARIMA y su Extensión Estacional **2**
1.1 Notación y Estructura del Modelo 2
1.2 Herramientas de Identificación: ACF y PACF 2

2 Principio de Parsimonia **3**
2.1 Justificación Matemática 3
2.2 Determinación de la Constante C 3

3 Criterios de Selección de Modelos **4**
3.1 AIC – Criterio de Información de Akaike 4
3.2 BIC – Criterio de Información Bayesiano 4
3.3 SSE – Suma de Errores Cuadrados 4
3.4 Comparación de Criterios 4

4 Test de Ljung-Box **5**

5 Diagrama de Flujo: Metodología Box-Jenkins para (S)ARIMAX **5**

6 Comparación Visual: AIC vs BIC y Penalización por Tamaño de Muestra **7**

7 Espacio de Búsqueda y Restricción de Parsimonia **7**

8 Ejemplo Aplicado: Ventas Mensuales con Estacionalidad **8**

9 Resumen y Conclusiones **8**

1. Introducción a los Procesos ARIMA y su Extensión Estacional

Los modelos ARIMA (AutoRegressive Integrated Moving Average) constituyen una de las herramientas más poderosas en el análisis de series de tiempo. Su extensión estacional, conocida como SARIMA, incorpora componentes que capturan patrones periódicos recurrentes. Cuando se añade una o más variables explicativas externas al sistema, el modelo se denomina **(S)ARIMAX**.

Definición General

El proceso **(S)ARIMA**$(p, d, q)(P, D, Q)_s$ modela una serie de tiempo Y_t capturando:

- Autocorrelación de corto plazo (componentes p, q)
- No estacionariedad mediante diferenciaciones (d, D)
- Dependencia estacional periódica (P, Q, s)

1.1. Notación y Estructura del Modelo

La forma general del modelo (S)ARIMAX se expresa mediante la ecuación:

$$\Phi_P(B^s)\,\phi_p(B)\,\Delta^d\Delta_s^D\,Y_t \;=\; \beta\,X_t \;+\; \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t \tag{1}$$

donde B es el operador de rezago ($BY_t = Y_{t-1}$), $\Delta = 1 - B$ es la diferencia regular y $\Delta_s = 1 - B^s$ la diferencia estacional.

La Tabla 1 resume el significado de cada parámetro del modelo.

?tablename? 1: Parámetros del modelo (S)ARIMAX$(p, d, q)(P, D, Q)_s$

Parámetro	Nombre	Función	Rango típico
p	Orden AR no estacional	Autoregresión de corto plazo	$0 \leq p \leq 3$
d	Diferenciación regular	Elimina tendencia determinista	$0 \leq d \leq 2$
q	Orden MA no estacional	Media móvil de corto plazo	$0 \leq q \leq 3$
P	Orden AR estacional	Autoregresión estacional	$0 \leq P \leq 1$
D	Diferenciación estacional	Elimina estacionalidad	$0 \leq D \leq 1$
Q	Orden MA estacional	Media móvil estacional	$0 \leq Q \leq 1$
s	Período estacional	Ciclo de repetición	$4, 12, 52$
β	Coeficiente exógeno	Efecto de la variable X_t	$\in \mathbb{R}$

1.2. Herramientas de Identificación: ACF y PACF

La identificación del orden del modelo se realiza principalmente a través de dos funciones:

ACF – Función de Autocorrelación

La ACF mide la correlación entre Y_t e Y_{t-k} para diferentes rezagos k. Es útil para identificar el orden q del componente MA: en un proceso MA(q) puro, la ACF se corta abruptamente después del rezago q.

PACF – Función de Autocorrelación Parcial (Esperanza Condicional)

La PACF mide la correlación entre Y_t e Y_{t-k} eliminando el efecto de los rezagos intermedios. Equivale a la esperanza condicional de Y_t dado el historial. Es útil para identificar el orden p del componente AR.

Limitación importante

Si se aplica la ACF directamente a un proceso AR puro, **no proporciona información útil** para determinar el orden, ya que decae de forma geométrica sin cortarse. En ese caso debe usarse la PACF.

2. Principio de Parsimonia

Principio de Parsimonia (Navaja de Occam en Series de Tiempo)

Ante dos modelos que explican igualmente bien los datos, **se prefiere el más simple**. En el contexto SARIMAX esto se traduce en la restricción:

$$p + d + q + P + D + Q \;\leq\; C \tag{2}$$

donde C es una constante que acota la complejidad total del modelo.

2.1. Justificación Matemática

El principio de parsimonia responde a la *compensación sesgo-varianza*. Formalmente, el error de predicción esperado se descompone como:

$$\mathrm{ECM}(\hat{Y}) \;=\; \underbrace{\mathrm{Sesgo}^2(\hat{Y})}_{\text{subajuste}} + \underbrace{\mathrm{Var}(\hat{Y})}_{\text{sobreajuste}} + \sigma_\varepsilon^2 \tag{3}$$

Un modelo con demasiados parámetros reduce el sesgo pero aumenta la varianza, deteriorando la capacidad predictiva fuera de muestra.

2.2. Determinación de la Constante C

La constante C no es un valor universal fijo; depende del contexto de la serie analizada. La Tabla 2 muestra las reglas prácticas más utilizadas.

?tablename? 2: Criterios para determinar la constante C en la restricción de parsimonia

Factor determinante	Regla	Valor de C resultante
Tamaño de muestra (n)	Mín. 10 obs. por parámetro	$C \approx n/10$
Período estacional $s = 12$	$P, Q \in \{0, 1\}$; $d + D \leq 2$	$C \approx 6$–8
Convención econométrica	$p, q \leq 3$; $P, Q \leq 1$	$C \leq 8$
Series financieras diarias	$s = 5$ o $s = 252$; $d = 0$ o 1	$C \leq 5$
Práctica general	Balance ajuste/complejidad	$C \in [6, 12]$

3. Criterios de Selección de Modelos

Una vez restringido el espacio de búsqueda mediante la condición (2), se evalúan las combinaciones de órdenes usando criterios de información que penalizan la complejidad.

3.1. AIC – Criterio de Información de Akaike

$$\text{AIC} \;=\; -2\,\ell(\hat{\theta}) \;+\; 2k \tag{4}$$

donde $\ell(\hat{\theta})$ es el valor máximo del logaritmo de la verosimilitud y k es el número de parámetros estimados.

3.2. BIC – Criterio de Información Bayesiano

$$\text{BIC} \;=\; -2\,\ell(\hat{\theta}) \;+\; k\ln(n) \tag{5}$$

La penalización $k\ln(n)$ es más severa que $2k$ cuando $n > e^2 \approx 7.4$, por lo que BIC tiende a seleccionar modelos más aust eros que AIC.

3.3. SSE – Suma de Errores Cuadrados

$$\text{SSE} \;=\; \sum_{t=1}^{n} \left(Y_t - \hat{Y}_t\right)^2 \tag{6}$$

Mide el ajuste dentro de muestra. Por sí sola no penaliza la complejidad, por lo que debe complementarse con AIC o BIC.

3.4. Comparación de Criterios

La Tabla 3 presenta una comparación sistemática de los criterios de selección disponibles.

?tablename? 3: Comparación de criterios de selección para modelos (S)ARIMAX

Criterio	Fórmula	Penalización	Uso principal	Tiende a
AIC	$-2\ell + 2k$	Moderada	Pronóstico	Modelos flexibles
BIC	$-2\ell + k \ln n$	Fuerte	Inferencia	Modelos aust eros
Log-verosimilitud	$\ell(\hat{\theta})$	Ninguna	Diagnóstico	Sobreajuste
SSE	$\sum \hat{\varepsilon}_t^2$	Ninguna	Ajuste en muestra	Sobreajuste

Nota: Se selecciona el modelo con **menor** AIC o BIC. Mayor log-verosimilitud indica mejor ajuste, pero sin penalización.

4. Test de Ljung-Box

Después de seleccionar el modelo con los criterios anteriores, se verifica que los residuos $\hat{\varepsilon}_t$ se comporten como ruido blanco mediante el test de Ljung-Box:

$$Q_{LB} \;=\; n(n+2)\sum_{k=1}^{m} \frac{\hat{\rho}_k^2}{n-k} \;\sim\; \chi^2_{m-p-q-P-Q} \tag{7}$$

donde $\hat{\rho}_k$ es la autocorrelación muestral del residuo en el rezago k y m es el número de rezagos considerados.

Interpretación

Si $Q_{LB} > \chi^2_\alpha$ (o el p-valor $< \alpha$), se rechaza la hipótesis nula de que los residuos son ruido blanco, indicando que el modelo no capturó toda la estructura de la serie y debe reidentificarse.

5. Diagrama de Flujo: Metodología Box-Jenkins para (S)ARIMAX

La Figura 1 ilustra el proceso completo de especificación, estimación y verificación de un modelo (S)ARIMAX.

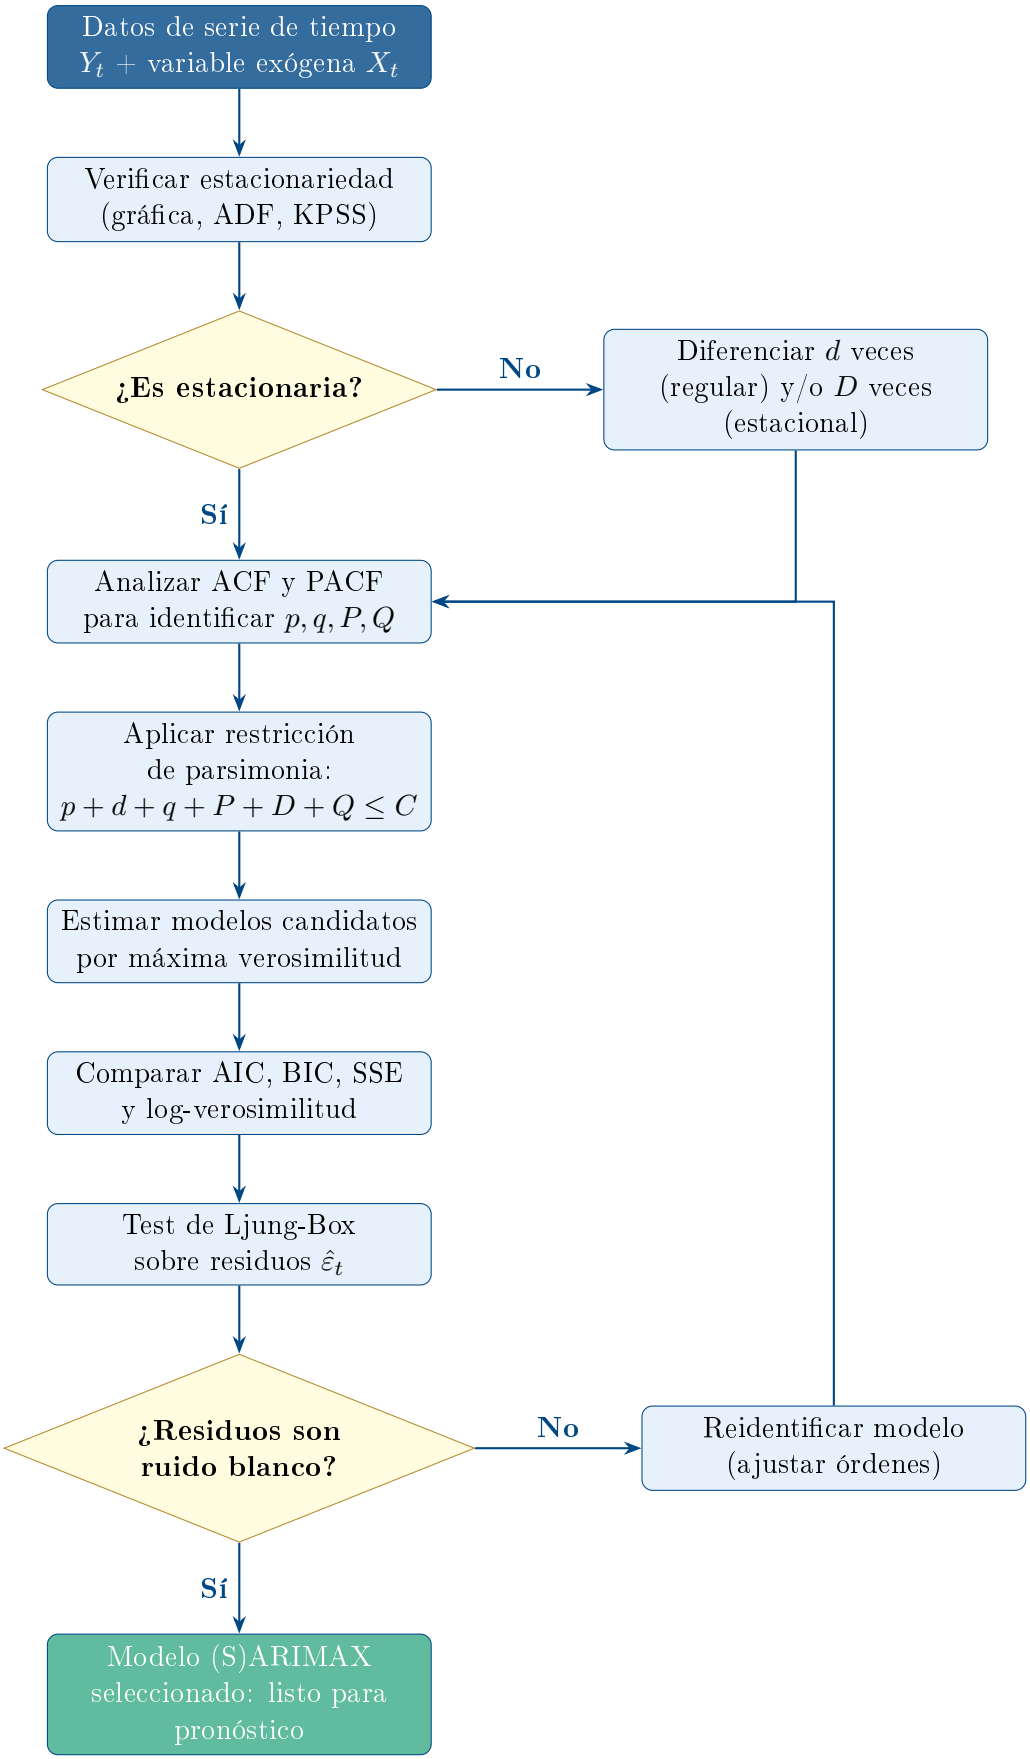

?figurename? 1: Metodología Box-Jenkins adaptada para la especificación de modelos (S)ARIMAX

6. Comparación Visual: AIC vs BIC y Penalización por Tamaño de Muestra

La Figura 2 muestra cómo la penalización del BIC crece más rápido que la del AIC conforme aumenta el tamaño de muestra n.

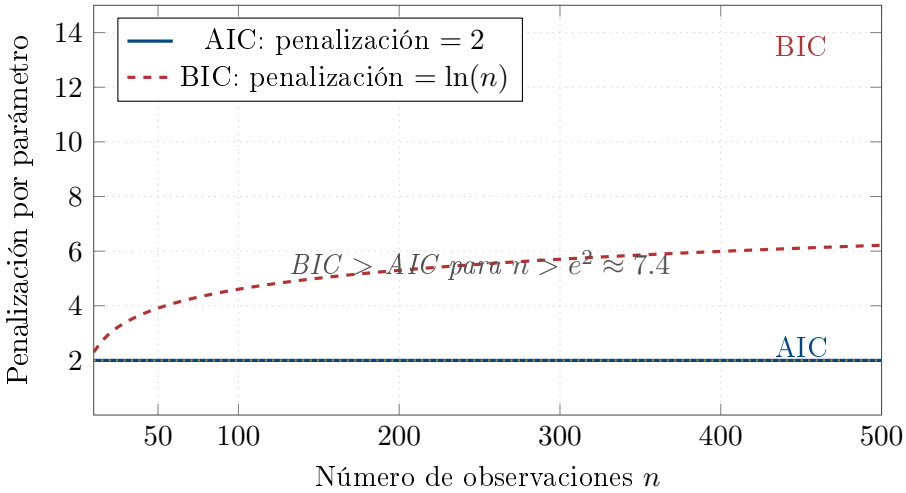

?figurename? 2: Comparación de la penalización por parámetro entre AIC y BIC en función del tamaño muestral

7. Espacio de Búsqueda y Restricción de Parsimonia

La Figura 3 ilustra cómo la restricción de parsimonia reduce el espacio de modelos candidatos a evaluar.

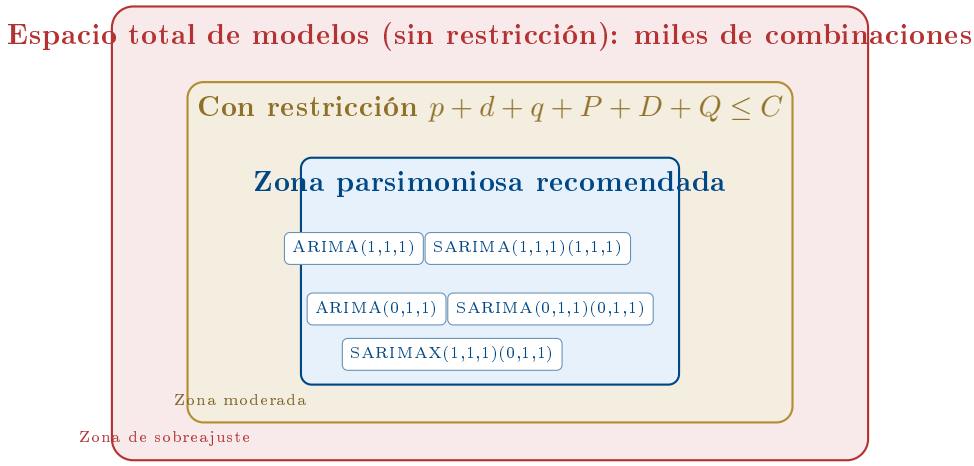

?figurename? 3: Reducción del espacio de búsqueda de modelos mediante el principio de parsimonia

8. Ejemplo Aplicado: Ventas Mensuales con Estacionalidad

Para ilustrar la metodología, consideremos una serie de ventas mensuales (en miles de pesos MXN) durante 6 años, con una variable exógena X_t que representa el gasto en publicidad.

La Tabla 4 muestra los modelos candidatos evaluados y sus criterios de selección.

?tablename? 4: Comparación de modelos SARIMAX candidatos para serie de ventas mensuales ($n = 72$, $s = 12$)

Modelo	$\sum$ órd.	k	Log-Ver.	AIC	BIC	LjungBox
ARIMA(1,1,1)	3	3	-312.4	630.8	638.5	$p = 0.42$
SARIMA(1,1,1)(1,1,1)$_{12}$	6	5	-298.1	606.2	619.1	$p = 0.67$
SARIMAX(1,1,1)(1,1,1)$_{12}$	6+X	6	-291.7	**595.4**	**610.7**	$p = 0.81$
SARIMAX(2,1,2)(1,1,1)$_{12}$	8+X	8	-289.9	595.8	616.4	$p = 0.79$
SARIMAX(3,1,3)(1,1,2)$_{12}$	11+X	10	-288.2	596.4	622.3	$p = 0.80$

Nota: El modelo seleccionado (en negrita) minimiza AIC y BIC simultáneamente, confirma residuos como ruido blanco ($p > 0.05$) y satisface la restricción de parsimonia con $\sum$ órd. $= 6 \leq C = 8$.

El modelo ganador es el **SARIMAX(1,1,1)(1,1,1)**$_{12}$, cuya ecuación estimada corresponde a la forma (1) con:

$$(1 - \hat{\phi}_1 B)(1 - \hat{\Phi}_1 B^{12})(1 - B)(1 - B^{12})Y_t = \hat{\beta} X_t + (1 + \hat{\theta}_1 B)(1 + \hat{\Theta}_1 B^{12})\varepsilon_t$$

9. Resumen y Conclusiones

?tablename? 5: Guía rápida de identificación de órdenes en (S)ARIMAX

Componente	Herramienta	Señal en el correlograma
Orden q (MA)	ACF	Corte abrupto tras el rezago q
Orden p (AR)	PACF	Corte abrupto tras el rezago p
Diferenciación d	Prueba ADF / gráfica	Serie no estacionaria: diferenci ar
Orden Q (SMA)	ACF en rezagos $s, 2s, \ldots$	Corte tras Q rezagos estacionales
Orden P (SAR)	PACF en rezagos $s, 2s, \ldots$	Corte tras P rezagos estacionales
Variable exógena X	Regresión preliminar	Significancia de $\hat{\beta}$

El principio de parsimonia, formalizado en la restricción $p+d+q+P+D+Q \leq C$, es la piedra angular de la metodología Box-Jenkins aplicada a series estacionales con variables exógenas. La combinación de ACF, PACF, criterios de información (AIC, BIC) y el test de Ljung-Box garantiza la selección de un modelo que equilibra ajuste y generalibilidad, evitando tanto el subajuste como el sobreajuste.